

FIAP GRADUAÇÃO

SISTEMAS DE INFORMAÇÃO

Computação Cognitiva e Semântica

PROF. ANTONIO SELVATICI

SHORT BIO



É engenheiro eletrônico formado pelo Instituto Tecnológico de Aeronáutica (ITA), com mestrado e doutorado pela Escola Politécnica (USP), e passagem pela Georgia Institute of Technology em Atlanta (EUA). Desde 2002, atua na indústria em projetos nas áreas de robótica, visão computacional e internet das coisas, aliando teoria e prática no desenvolvimento de soluções baseadas em Machine Learning, processamento paralelo e modelos probabilísticos. Desenvolveu projetos para Avibrás, IPT e Systax.

PROF. ANTONIO SELVATICI

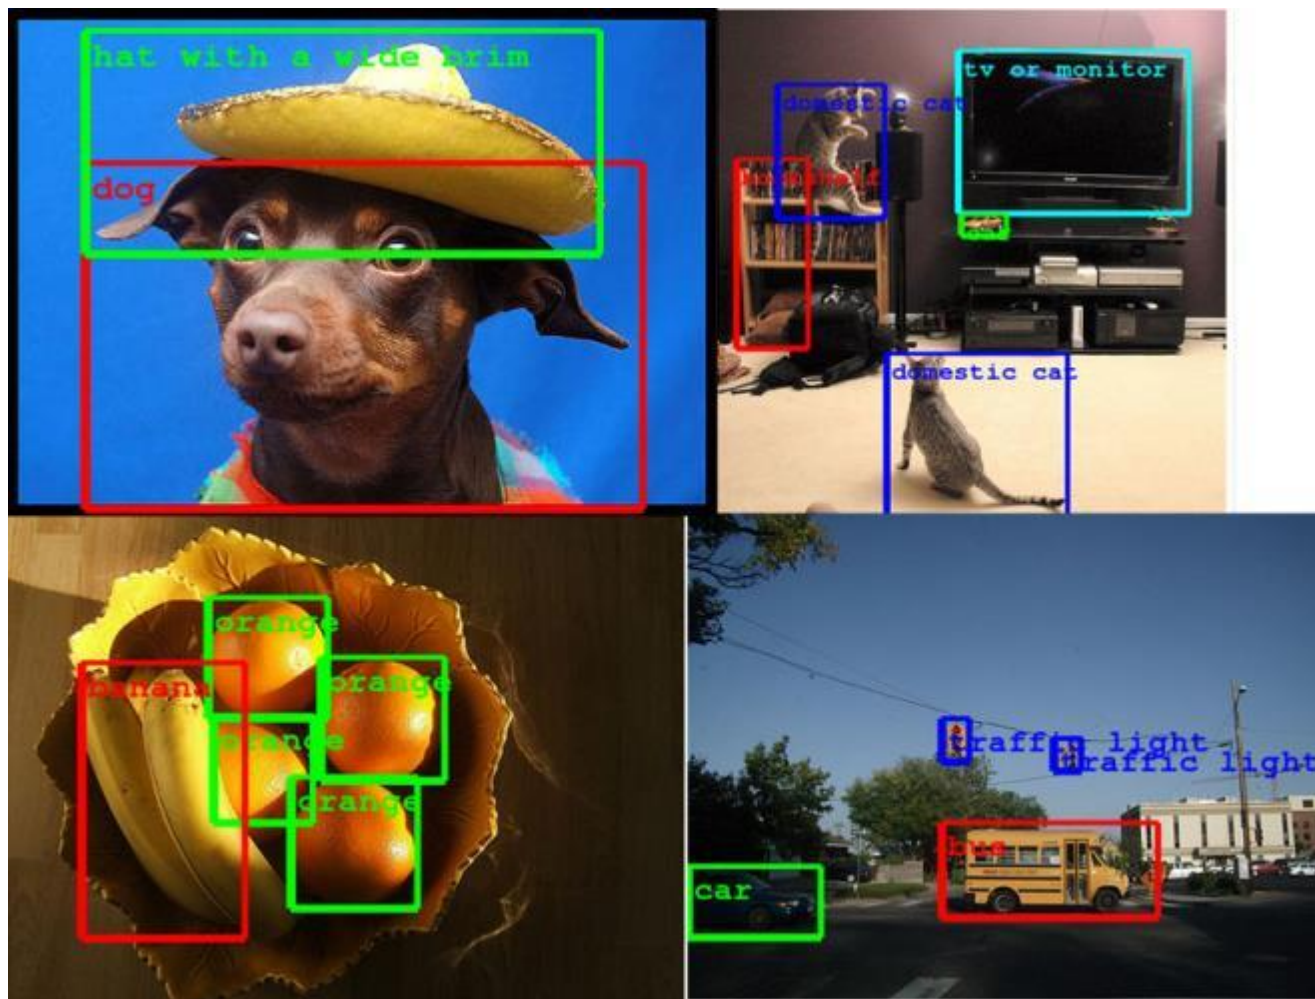
profantonio.selvatici@fiap.com.br

2. MACHINE LEARNING

O que é Reconhecimento de Padrões

- O ser humano consegue reconhecer padrões de formas, rostos, sons com facilidade. Embora o computador tenha uma grande capacidade de realizar cálculos matemáticos, ensiná-lo a reconhecer esses padrões é uma árdua tarefa
- Como **reconhecimento** ou **classificação de padrões** entende-se a determinação de uma **classe** ou **categoria** para um conjunto de dados brutos, extraídos a partir de um experimento, um site na web, imagens de uma câmera, etc. Em geral, temos um conjunto predefinido de possíveis classes em que esses dados podem ser classificados, mas nem sempre isso ocorre.
- Exemplos de reconhecimento de padrões por computador
 - Identificar o conteúdo e o autor de uma gravação telefônica
 - Reconhecer o rosto de uma pessoa em imagens de vídeo
 - Determinar o assunto e o autor de um texto a partir de suas palavras

Reconhecimento de padrões em imagens



<http://adrenaline.uol.com.br/2014/09/08/28151/tecnologia-de-reconhecimento-de-objetos-do-google-diferencia-seu-gato-de-um-sofa>

■ Etapas do Reconhecimento de Padrões

- Embora haja diversas abordagens para o desenvolvimento de técnicas de RP, identificam-se algumas procedimentos básicos que presentes na maior parte das técnicas:
 - **Pré-processamento:** etapa em que os dados brutos são processados para ressaltar as informações mais importantes para o reconhecimento de padrões
 - **Extração de atributos:** etapa em que as informações específicas a serem utilizadas na classificação são obtidas a partir dos dados pré-processados
 - **Classificação:** processo em que os atributos são analisados para a determinação da classe ou categoria a que esses dados pertencem
- Para melhor entendermos como essas etapas se desenrolam no processo de RP, vamos usar o exemplo proposto por Duda e Hart no livro *Pattern Classification*: a classificação de imagens digitais de peixes do tipo salmão e badejo.


Ilustração do exemplo: que diferenças podemos apontar?




I Atributos usados para a classificação

- Para projetarmos um classificador que resolva esse problema, temos que escolher os atributos que melhor caracterizam a diferenças entre os peixes. Vamos compará-los com relação ao brilho e ao comprimento do peixe.
- Vemos que o atributo do brilho da imagem e do comprimento do peixe sozinhos não são capazes de determinar se a imagem é de salmão ou badejo, mas são alguns indicativos.

Atributos usados para a classificação



Contagem de exemplos com base no comprimento




Contagem de exemplos com base no brilho

■ Combinando os atributos

- Se x representa o brilho e l representa o comprimento, seja o **vetor de atributos** (x, l) , obtido a partir dos dados extraídos de cada imagem.
- Quando representamos os dados (x, l) na forma de um gráfico de dispersão, podemos notar que há regiões com maior probabilidade de indicar salmão e outras com maior probabilidade de indicar badejo.

■ Comparação dos vetores de atributos



- Os classificadores de padrões definem, de forma implícita ou explícita, linhas ou superfícies de separação entre as classes.
- Na figura, vemos qual é a melhor reta que pode separar os exemplares de salmão e de badejo com base no comprimento e no brilho


■ Classificação das imagens dos peixes

- **Pré-processamento:** antes de proceder à classificação, as imagens devem ser tratadas para eliminar ruídos e segmentar apenas a região contendo o peixe
- **Extração de atributos:** com base na imagem segmentada, extraímos os atributos de interesse. No nosso caso, medimos a luminosidade média dos pixels e o comprimento do peixe na imagem
- **Classificação:** a partir de um classificador especificamente projetado para tal, verificamos se o vetor de atributos cai na região interpretada como salmão ou na região interpretada como badejo.
- **Como realizar a classificação?**
 - Existem algoritmos estatísticos que definem essa “linha de separação” a partir de exemplos já classificados (ou rotulados) , ou ainda mesmo se eles não estiverem classificados
 - As redes neurais são um tipo de classificador, mas existem vários outros


I Diferenças entre classificadores

- **Pré-processamento:** antes de proceder à classificação, as imagens devem ser tratadas para eliminar ruídos e segmentar apenas a região contendo o peixe
- **Extração de atributos:** com base na imagem segmentada, extraímos os atributos de interesse. No nosso caso, medimos a luminosidade média dos pixels e o comprimento do peixe na imagem
- **Classificação:** a partir de um classificador especificamente projetado para tal, verificamos se o vetor de atributos cai na região interpretada como salmão ou na região interpretada como badejo.
- **Tipos de classificadores:** com base no tipo de superfície de separação entre as regiões correspondentes às diferentes classes, o classificador pode ser:
 - **Linear:** define separadores lineares entre as regiões, como retas ou planos (caso do classificador representado anteriormente)
 - **Não-linear:** define separadores não-lineares, como superfícies quadráticas, regiões fechadas e outras formas genéricas

Exemplo de classificador linear



Exemplo de classificador não-linear



As fases da classificação


- **Como realizar a classificação?**
 - Existem algoritmos estatísticos que definem essa “linha de separação” a partir de exemplos já classificados (ou rotulados) , ou ainda mesmo se eles não estiverem classificados
 - As redes neurais são um tipo de classificador, mas existem vários outros
- Uma vez obtida a linha ou superfície de separação que melhor diferencia os atributos pertencentes a cada classe, realizar a classificação equivale a apontar a qual a região delimitada um certo vetor de atributos se encontra
- Porém, como chegar a definir a linha ou superfície de separação? Através de um processo de **treinamento** ou **aprendizado**!
- Assim, o processo de classificação compreende duas fases:
 - **Fase de treinamento:** exemplos de vetores de atributos provenientes de diferentes classes (amostras de treinamento) são utilizados para definir, implícita ou explicitamente, a superfície de separação.
 - **Fase de teste:** uma amostra de vetor de atributo é classificada de acordo com a superfície de separação obtida na fase de treinamento

Treinamento de classificadores


- Dependendo do tipo de informação utilizada durante o processo de aprendizado de um classificador, ele pode ser:
 - **Aprendizado supervisionado:** quando o classificador utiliza amostras de vetores de atributos rotulados com a classe correspondente durante a fase de treinamento
 - **Aprendizado semi-supervisionado:** quando o classificador recebe como entrada amostras de vetores de atributos e alguma outra informação sobre esses dados; em geral há a presença de alguns dados já rotulados
 - **Aprendizado não supervisionado:** quando o classificador determina as superfícies de separação entre as classes com base no agrupamento dos vetores de atributos disponíveis, sem qualquer informação adicional

Exemplo de aprendizado não supervisionado

Dados originais antes do treinamento



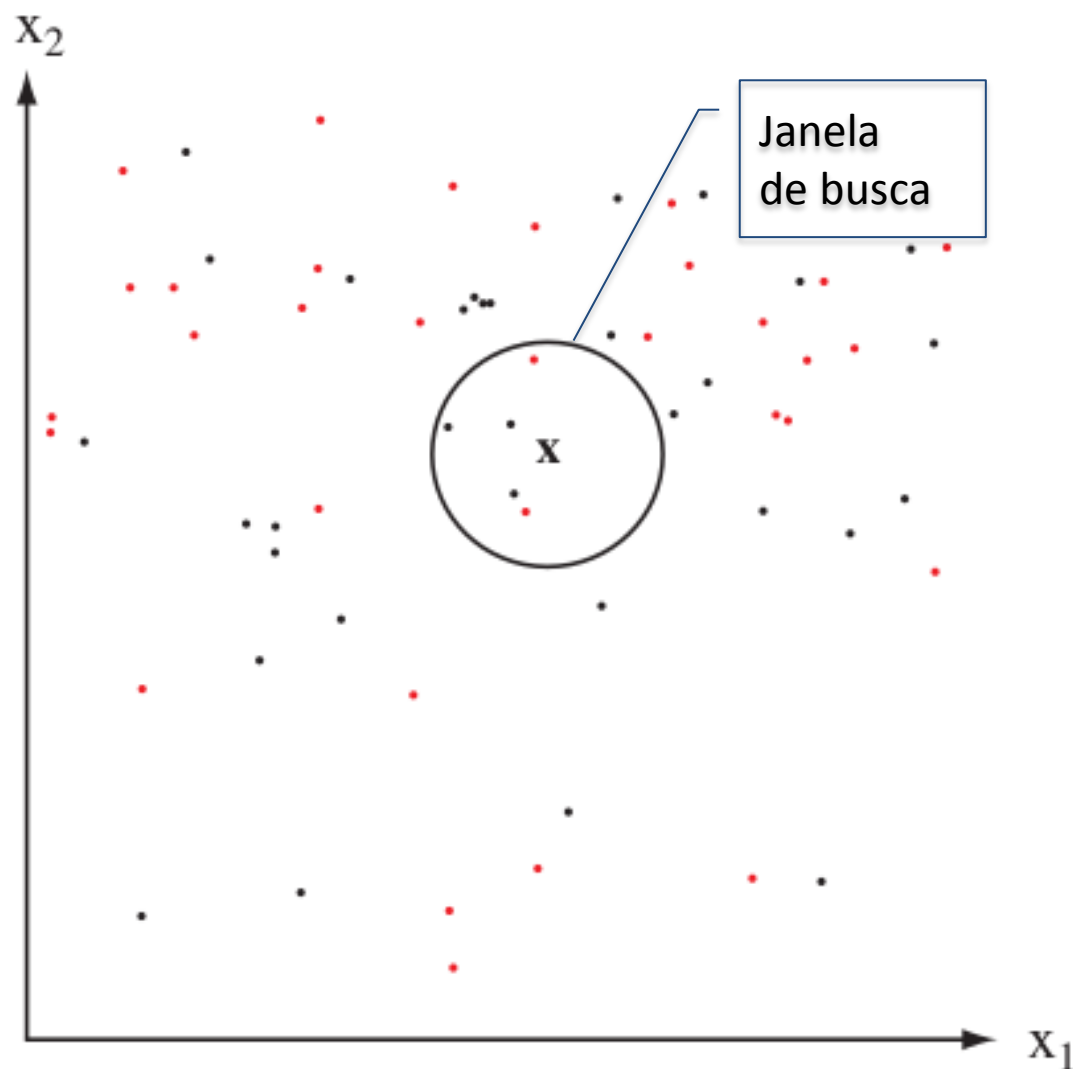
Dados agrupados após o treinamento



■ Classificadores simples: classificação com base em instâncias

- Uma forma simples de realizar a classificação de padrões é utilizar diretamente as amostras de treinamento rotuladas para definir a superfície de separação e decidir a classe com base em uma comparação direta
- Esse tipo de classificação é denominada **classificação com base em instâncias**, cujas técnicas se diferenciam pela estratégia de comparação entre o exemplo de teste e as amostras de treinamento
- O classificador baseado em instâncias mais conhecido é o chamado **k-vizinhos-mais-próximos** (*k-nearest-neighbors*, ou kNN)
 - O vetor de atributos é comparado com um certo número (k) de amostras de treinamento que mais se assemelham a ele
 - A classe que for representada em mais rótulos nas amostras de treinamento selecionada é escolhida para o vetor de atributos

Classificação por 5-vizinhos-mais-próximos




Considerações sobre kNN

- O número de vizinhos a serem pesquisados (k) é, em geral, ímpar
- Até um certo limite, quanto maior o número de vizinhos pesquisados, maior a chance de acerto na classificação, porém um conjunto muito grande pode levar a janela de busca a “invadir” as regiões com predominância de outras classes
- A comparação entre a amostra de teste e as amostras de treinamento é, em geral, baseada na distância euclidiana.
 - Se o vetor de atributos for $v = (x, y, z)$, a distância euclidiana entre as amostras v_1 e v_2 será dada por:
 - $||v_1 - v_2|| = \sqrt{[(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2]}$
- Se houver muitas amostras de treinamento, pode ser inviável ter que mantê-las todas na memória para realizar a classificação
- Além do mais, para encontrar os k vizinhos mais próximos é necessário percorrer todas as amostras de aprendizado e medir a distância até a amostra de teste, o que pode demandar muito tempo computacional
 - Para melhorar o desempenho da classificação, as amostras de treinamento são, em geral, armazenadas em uma estrutura denominada **kD-tree**, onde **k** é o número de atributos empregados na classificação

Problemas com o classificador kNN

- Podemos considerar o kNN como um classificador não-linear, já que a superfície de separação não é uma reta ou plano
- No caso de $k=1$ (vizinho mais próximo) se a amostra de teste cair próximo a um ponto espúrio ou ruidoso, teremos um resultado ruim de classificação
- Muitas vezes queremos definir superfícies de separação que desconsiderem pontos ruidosos, generalizando melhor o resultado



REFERÊNCIAS

- Stuart Russel & Peter Norvig. Inteligência Artificial – tradução da 2ª ed. Editora Campus, 2004
- Duda, Hart & Stork. Pattern Classification, 2nd. Ed., 2000, Cap. 1





Copyright © 2017 Prof. Antonio Selvatici

Todos direitos reservados. Reprodução ou divulgação total ou parcial deste documento é expressamente proibido sem o consentimento formal, por escrito, do Professor (autor).